


Ağaçlarla Tanı Koyma Oyunu!

Senaryo: Yabancı gezegen yaratıklarını inceleyen bir Xenobiologsun. Bu yaratıklar zaman zaman hastalanıyor. Hikayemizin başında, bazıları "ague" adlı yabancı gezegen hastalığına yakalanmış 10 yaratığın kaydına sahipsin. Yaratıkları ague hastalığına karşı savunmasız kılan şey ne olabilir?

- İlk başta soldaki seçimi **training (eğitim)** olarak bırakın.
- Yaratıklarınıza ait 10 yeni vakayı otomatik olarak oluşturmak için **"Make New Cases"** simgesine tıklayın.

Veri tablosunda, **Xhealth** sütunu onların hasta mı yoksa sağlıklı mı olduğunu gösterir.


- Xhealth'i tahmin etmek için başka hangi verileri kullanabileceğinizi bulun.
- Verinin bir grafiğini oluşturmak yardımcı olabilir. Eğer daha önce CODAP'ta hiç grafik oluşturmadıysanız, bunu deneyin.



- Fikirlerinizi doğrulamak için ek vakalar alın. Bunu, sağ taraftaki küçük **Arbor Xenobiological Services** panelinde bulunan **make new cases** düğmesine basarak yapın.
- Kendinizden emin olduğunuzda, soldaki seçimi **one by one (teker teker)** olarak değiştirin.

Şimdi tek tek vakalara tanı koyacaksınız. Bakın bakalım doğru mu yapıyorsunuz. Eğer sürekli doğru yapmıyorsanız, verinizi yeniden gözden geçirin ve neyi kaçırmış olabileceğinizi görün. (Puan kazandığınızı fark edin!)

Bunu iyice çözdüğünüzü düşündüğünüzde, bu yaratıklara tanı koyma sürecini otomatikleştireceğiz. Bunun için tanıda ağaçların kullanılmasıyla ilgili bir sonraki bölüme geçin.




Teşhis İçin Ağaçlar

Bir hastaya tanı koymak için ona bir dizi soru sorarız. Bu sorulara verilen cevaplar, onun bu hastalığa sahip olup olmadığını tahmin etmemize yardımcı olur. Bir sorunun cevabı ya bir teşhise (hasta / sağlıklı) ya da başka bir soruya yönlendirir. Bu süreci temsil etmek ve otomatikleştirmek için **karar ağacını** kullanacağız.


- Karar ağacını açmak için sağ üstteki **“tree”** simgesine basın.
- Ağacı, başka hiçbir şeyin üstünü kapatmayacak şekilde taşıyın (Veri tablonuzu küçültmeniz gerekebilir.).
- İşe **“hedef değişkeninizi”** yani tahmin etmek istediğiniz şeyi ağaca sürükleyerek başlayın.

Karar ağacınız bir sonraki resimdeki gibi görünmelidir ancak sizin sayılarınız farklı olabilir.



- Ağacınızı büyütmek için tablodaki değişken adlarını ağaca sürükleyin ve bunları **“nodes (düğümmler)”** üzerine bırakın.
- Muhtemelen saç renginin önemli olduğunu zaten fark ettiniz; bu yüzden tablodan **hair** değişkenini sürükleyin ve beyaz kutunun üzerine bırakın.

Şunu görmelisiniz:



Bunun anlamı şudur:

- En üstteki kutu size **Xhealth**'i tahmin ettiğinizi ve **sick** değerinin “pozitif” olduğunu söyler.
- Bir sonraki kutuya bakın (şekildeki kutu; sizdeki sayılar farklı olabilir). Tüm yaratıklar arasında 10'un 6'sı (%50) hastadır.

İlk “sorumuz” şudur: Hastanın saç rengi nedir? (Bu yüzden alt şeritte **hair...?** yazmaktadır.) İki olası cevap vardır: **blue** ve **pink**. Her biri farklı bir kutuya götürür.

- Soldaki kutu, mavi saçlı 4 yaratık olduğunu ve bunların hiçbirinin (%0) hasta olmadığını söyler.
- Sağdaki kutu ise pembe saçlı 6 yaratık olduğunu ve bunların hepsinin (%100) hasta olduğunu söyler.

Not: Daha fazla bilgi almak için herhangi bir kutunun veya bağlantının üzerine de gelebilirsiniz.


Pozitif ve Negatif

Tıbbi alanda insanlar genellikle “pozitif” ve “negatif” tanı ve sonuçlardan bahseder. Biz de ağaç aracımızda “hasta” durumunu pozitif olarak düşüneceğiz. Tıpkı ague hastalığı için yapılan bir testin pozitif çıkması gibi. Hangi varlıkların ague hastalığına sahip olduğunu tahmin etmek için onları “pozitif” olarak etiketleyeceğiz.

Otomasyon

Diyelim ki tanılarımızı otomatikleştirmek istiyoruz. Bunun için ağaca, pembe saç kutusunu pozitif (“hasta”) gruba ve mavi saç kutusunu negatif (“sağlıklı”) gruba atamasını söylememiz gerekir. Üzerinde (?) bulunan gri daireler, o kutulara henüz tanı atamadığınızı gösterir.

- Tanı atamak için onlara tıklayın. Görünümün şöyle olmasını sağlayın:



Karar Ağacını Okuyalım

Oluşturduğunuz karar ağacına göre aşağıdaki soruları yanıtlayınız:

Soru	Cevap
Kök düğüm (root node) kaç vaka içermektedir? Bu vakaların yüzde kaçını sick (hasta) durumundadır? Bu oran size veri seti hakkında ne söylemektedir?	
Mavi saçlı (blue hair) kutuda kaç vaka bulunmaktadır? Bu vakaların kaçını sick (hasta) durumundadır? Bu gruptaki hastalık oranını nasıl yorumlarsınız?	
Pembe saçlı (pink hair) kutuda kaç vaka bulunmaktadır? Bu vakaların kaçını sick (hasta) durumundadır? Bu sonuç, saç rengi ile hastalık arasında nasıl bir ilişki olduğunu düşündürmektedir?	
Hangi kutu “negatif” (hasta) olarak etiketlenmiştir? Bu kararı verirken hangi ölçütü kullandınız? Alternatif bir etiketleme mümkün müydü? Açıklayınız.	
Pembe saçlı (pink hair) kutuda kaç vaka bulunmaktadır? Bu vakaların kaçını sick (hasta) durumundadır? Bu sonuç, saç rengi ile hastalık arasında nasıl bir ilişki olduğunu düşündürmektedir?	
Saç rengi değişkeni bu veri setinde iyi bir ayırıcı (predictor) mıdır? Neden?	
Eğer yeni bir vaka gelseydi, yalnızca saç rengine bakarak doğru tahmin yapma olasılığınız hakkında ne söyleyebilirsiniz?	

Karışıklık Matrisi (Confusion Matrix)

Bir karar ağacı oluşturduk ve artık yeni vakalar için tahmin yapabiliyoruz. Peki modelimizin **ne kadar iyi çalıştığını** nasıl anlayacağız?

Confusion Matrix, oluşturduğunuz karar ağacının tahminlerini gerçek sonuçlarla karşılaştıran bir tablodur. Bu tablo sayesinde modelinizin **hangi uzaylıları doğru teşhis ettiğini**, hangilerinde ise **hata yaptığını** sistematik olarak görebilirsiniz.

- Ağacın altındaki renkli kutulara dikkat et. Bu kutular, ağacın teşhis ettiği **Gerçek Pozitif (TP)** vb. sayıları gösteriyor. Daha fazla ayrıntı için üzerine gelin.

3.1 Kavramları Tanıyalım

		Gerçek		Toplam
		HASTA (-)	SAĞLIKLI (+)	
Tahmin	HASTA (-)	TP (Doğru Pozitif)	FP (Yanlış Pozitif)	TP + FP
	SAĞLIKLI (+)	FN (Yanlış Negatif)	TN (Doğru Negatif)	FN + TN
Toplam		TP + FN	FP + TN	N

Karışıklık matrisini incele. Her hücrenin ne anlama geldiğini kendi cümlelerinle açıklayın:

TP (Doğru Pozitif)	Tahmin: Hasta ✓ Gerçek: Hasta <i>Model 'hasta' dedi, gerçekten de hasta.</i>
TN (Doğru Negatif)	Tahmin: Sağlıklı ✓ Gerçek: Sağlıklı <i>Model 'sağlıklı' dedi, gerçekten de sağlıklı.</i>
FP (Yanlış Pozitif)	Tahmin: Hasta ✗ Gerçek: Sağlıklı <i>Model 'hasta' dedi, aslında sağlıklı. (Tip I Hata)</i>
FN (Yanlış Negatif)	Tahmin: Sağlıklı ✗ Gerçek: Hasta <i>Model 'sağlıklı' dedi, aslında hasta. (Tip II Hata)</i>

Soru: Aşağıdaki hata türlerini tıbbi bağlamda değerlendiriniz:

- **FP (Yanlış Pozitif):** Sağlıklı bir bireyin hasta olarak sınıflandırılması
- **FN (Yanlış Negatif):** Hasta bir bireyin sağlıklı olarak sınıflandırılması

Sizce hangi hata türü daha tehlikelidir? (FP mi FN mi?) Seçiminizin gerekçesini açıklayın.

Cevap:

CODAP'ten Değerleri Oku

- Karar ağacınızı istediğiniz şekilde ayarladıktan sonra **Arbor Xenobiological Services**'e geri dönün ve soldaki seçenekten **auto**'yu seçin.
- Ardından 10 vaka oluşturmak için **run tree** (ağacı çalıştır) düğmesine tıklayın.

Soru: Karar ağacınız 10 yeni hastayı otomatik olarak teşhis edecek. Ağacınız nasıl bir performans sergiledi?

Cevap:

- Karar ağacında “table” sekmesine tıklayarak **karışıklık matrisini (confusion matrix)** açın.

2025k

classification (decision) tree

tree

table

mosaic

networks

settings

help!

Xhealth

20 cases

prediction

well (20)

sick (0)

no prediction (0)

truth

well (13)

sick (7)

13

7

0

0

0

0

- Karar ağacının altındaki renkli kutularda verilen değerleri inceleyiniz. Bu değerleri arka sayfadaki tabloya kaydedin.

Değer	Sayı	Ne anlama geliyor? (Kendi cümlelerinizle açıklayınız.)
TP (Doğru Pozitif)		
TN (Doğru Negatif)		
FP (Yanlış Pozitif)		
FN (Yanlış Negatif)		
N (Toplam)		

Performans Metrikleri

Metrik	Formül	Ne Ölçer? (Açıklama)
Doğruluk (Accuracy)	$(TP + TN) / N$	Tüm tahminler içinde doğru olanların oranını gösterir.
Duyarlılık (Sensitivity / Recall)	$TP / (TP + FN)$	Gerçekten hasta olan bireylerin ne kadarının doğru şekilde “hasta” olarak tespit edildiğini gösterir (True Positive Rate).
Özgüllük (Specificity)	$TN / (TN + FP)$	Gerçekten sağlıklı olan bireylerin ne kadarının doğru şekilde “sağlıklı” olarak sınıflandırıldığını gösterir (True Negative Rate).
Kesinlik (Precision)	$TP / (TP + FP)$	Modelin “hasta” dediği vakaların ne kadarının gerçekten hasta olduğunu gösterir.

CODAP'te oluşturduğunuz karışıklık matrisine göre aşağıdaki metrikleri hesaplayın.

Metrik	Hesaplama (Adım Adım)	Sonucu Yorumlayın
Doğruluk		
Duyarlılık		
Özgüllük		
Kesinlik		

Soru: Bir Xenobiyolog olarak hangi metriği öncelikli olarak kullanırsınız? Seçtiğiniz metriğin neden bu problem için en uygun ölçüt olduğunu açıklayın.

Cevap:

Soru: Mevcut metriklerden farklı olacak şekilde, modelin performansını değerlendirmek için **yeni bir metrik tanımlayın** (Birden fazla metriği birleştirebilirsiniz).

a) Oluşturduğunuz metriğin formülünü yazın.

b) Oluşturduğunuz ölçü neyi daha iyi yakalamaktadır?

c) Bu ölçü hangi durumlarda tercih edilmelidir?

Yeni Bir Metriği Tanıyalım

Metrik	Formül	Ne Ölçer? (Açıklama)
Yanlış Sınıflandırma Oranı (MCR: Misclassification Rate)	$(FP + FN) / N$	Tüm tahminler içinde hatalı olanların oranını gösterir (MCR = 1 – Accuracy).

CODAP'te oluşturduğunuz karışıklık matrisine göre TP, TN, FP, FN değerlerini kullanarak aşağıdaki metrikleri hesaplayın.


Metrik	Hesaplama (Adım Adım)	Sonucu Yorumlayın
MCR		

Keşfedelim

- Henüz yapmadıysanız, koyduğunuz teşhisin neden işe yaradığını göstermek için verinin grafiklerini oluşturun.
- Veri tablosunda ya da bir grafikte bir vakaya tıklayın. Bunun ağaçta nasıl yansıdığını görün.
- Ağaçtaki alt kutulardan birine tıklayın. Bunun tabloda ve varsa grafiklerde nasıl yansıdığını görün.
- Kötü ağaçlar yapmayı deneyin ya da daha büyük ağaçlar oluşturup nasıl çalıştıklarını görün.
- Puanınızı neyin etkilediğini bulun.
- Diğer senaryoları deneyin. Onlar daha zordur. (Birini seçtiğinizde eski veriniz kaybolacaktır. Ayrıca değişkenleri yapılandırmanız gerekecek; aşağıya bakın.

Değişkenleri Yapılandırma

Daha zor senaryolarda çalışırken, sormak istediğiniz sorunun varsayılan ayarın izin verdiğinden farklı olmasını isteyeceğinizi fark edeceksiniz. Örneğin **ağırlık** hakkında soru sormak istediğinizi düşünün. Her soru ikili olduğu için yalnızca ağırlığın belli bir sayının üstünde mi altında mı olduğunu sorabilirsiniz. Ama hangi sayı?



- **Değişkeni yapılandırmanız** gerekir. Ağacın içinde değişken adının üzerine geldiğinizde, sol tarafında bir **dışli çark** belirlediğini göreceksiniz. Yapılandırma penceresini açmak için ona tıklayın.

Configure "weight"

left branch	right branch
label: < 215	label: >= 215
weight < 215	weight >= 215
attribute type: numeric swap left and right: ↔	

Sayısal bir değişken için:

- **Kesme noktasını (cut point)** ayarlayabilirsiniz.
- İşleci, yani **büyüktür** ya da **küçüktür** seçimini yapabilirsiniz.

Kategorik bir değişken için:

- Olası değerleri sola ve sağa taşımak için üzerlerine tıklayabilirsiniz.

Herhangi bir değişken için:

- Sol / sağ düğmesine tıklayarak sol ve sağ değerleri yer değiştirebilirsiniz.
- Etiketleri daha anlamlı olacak şekilde değiştirebilirsiniz. Örneğin ağırlık için **heavy (ağır)** ve **light (hafif)** etiketlerini kullanabilirsiniz.