

CODAP Arbor'da Titanic Verisi

Şimdiye kadar Xeno veri setinde karar ağaçlarının nasıl oluşturulduğunu, nasıl yorumlandığını ve nasıl değerlendirildiğini öğrendik. Ancak gerçek veri setleri her zaman bu kadar düzenli ve açık örüntüler içermez. Bu bölümde Titanic veri setinden alınan örneklemeler ile çalışacağız.



Bir karar ağacının işe yarayıp yaramadığını anlayabilmek için veriyi iki parçaya ayırırız:

- **Eğitim veri seti (training set):** Modelin örüntüleri öğrenmesi için kullanılır.
- **Test veri seti (test set):** Modelin yeni ve daha önce görmediği veriler üzerinde ne kadar başarılı olduğunu görmek için kullanılır.

Bu çalışmada veri setinin yaklaşık **%80'i eğitim, %20'si test** için ayrılmıştır. Bunun temel nedeni, modelin öğrenebilmesi için yeterince büyük bir veri grubuna ihtiyaç duymasıdır. Eğer eğitim veri seti çok küçük olursa, model verideki ilişkileri yeterince öğrenemeyebilir. Buna karşılık test veri setinin de tamamen ortadan kalkmaması gerekir. Çünkü modelin gerçekten **genelleme yapıp yapamadığını** ancak test verisiyle anlayabiliriz.

Karar Ağacını Oluşturalım – Eğitim Veri Seti 1

Aşağıdaki adımları sırayla uygulayınız:

- CODAP'e **titanic_egitim_veri_seti1.csv** isimli veri setini yükleyiniz.
- **Hedef değişkeni** ağacın en üst kısmına sürükleyip bırakın.
- Veri tablosundaki **sex** değişkenini alıp ağacın üzerindeki **beyaz düğüme** sürükleyip bırakın.
- **Dişli çark** simgesine tıklayın. **Female** tarafını **pozitif** (*hayatta kaldı = 1*), **male** tarafını **negatif** (*hayatını kaybetti = 0*) olacak şekilde düzenleyin.
- Ağacın altındaki **gri dairelere (?)** tıklayarak **female** kutusunu **pozitif**, **male** kutusunu **negatif** olarak etiketleyin.

Karar ağacı tamamlandı. Bu aşamada herkesin **aynı karar ağacına** sahip olması beklenmektedir.

Karar Ağacını Okuyalım – Eğitim Veri Seti 1

Soru	Cevap
Kök düğüm kaç yolcu içeriyor? Kaçı hayatta?	
Female (kadın) kutusunda kaç kişi var? Kaçı hayatta?	
Male (erkek) kutusunda kaç kişi var? Kaçı hayatta?	
Hangi kutu 'pozitif' (hayatta) olarak etiketlendi?	

Değerleri Yazalım – Eğitim Veri Seti 1

Metrik	Formül	Hesaplama (Adım Adım)
Doğruluk (Accuracy)	$(TP + TN) / N$	
Duyarlılık (Sensitivity)	$TP / (TP + FN)$	
Özgüllük (Specificity)	$TN / (TN + FP)$	
Kesinlik (Precision)	$TP / (TP + FP)$	
Yanlış Sınıflandırma Oranı (MCR)	$(FP + FN) / N$	

Karar Ağacını Oluşturalım – Test Veri Seti 1

Şimdi aynı karar ağacını **farklı bir veri setine (test seti)** uygulayacaksınız. Bu veri seti de Titanic yolcularına ait ancak ağacın **daha önce hiç görmediği kayıtları** içermektedir.

Aşağıdaki adımları sırayla uygulayınız:

- CODAP'e **titanic_test_veri_seti1.csv** isimli veri setini yükleyiniz.
- **Hedef değişkeni** ağacın en üst kısmına sürükleyip bırakın.
- Veri tablosundaki **sex** değişkenini alıp ağacın üzerindeki **beyaz düğüm**e sürükleyip bırakın.
- **Dişli çark** simgesine tıklayın. **Female** tarafını **pozitif** (*hayatta kaldı = 1*), **male** tarafını **negatif** (*hayatını kaybetti = 0*) olacak şekilde düzenleyin.
- Ağacın altındaki **gri dairelere (?)** tıklayarak **female** kutusunu **pozitif**, **male** kutusunu **negatif** olarak etiketleyin.

Karar ağacı tamamlandı. Bu aşamada herkesin **aynı karar ağacına** sahip olması beklenmektedir.

Karar Ağacını Okuyalım – Test Veri Seti 1

Soru	Cevap
Kök düğüm kaç yolcu içeriyor? Kaçı hayatta?	
Female (kadın) kutusunda kaç kişi var? Kaçı hayatta?	
Male (erkek) kutusunda kaç kişi var? Kaçı hayatta?	
Hangi kutu 'pozitif' (hayatta) olarak etiketlendi?	

Değerleri Yazalım – Test Veri Seti 1

Metrik	Formül	Hesaplama (Adım Adım)
Doğruluk (Accuracy)	$(TP + TN) / N$	
Duyarlılık (Sensitivity)	$TP / (TP + FN)$	
Özgüllük (Specificity)	$TN / (TN + FP)$	
Kesinlik (Precision)	$TP / (TP + FP)$	
Yanlış Sınıflandırma Oranı (MCR)	$(FP + FN) / N$	

Soru: Eğitim ve test seti metrikleri arasında büyük bir fark var mı? Varsa bu fark neden olabilir?

Cevap:

Düşünelim: Bir model eğitim verisinde çok iyi performans gösterip test verisinde belirgin biçimde kötü performans sergiliyorsa bu duruma ne ad verilir? Bu durumun ortaya çıkmasına ne sebep olmuş olabilir?

Soru: Aşırı öğrenme (overfitting) nedir? Bu senaryoda neden aşırı öğrenme gerçekleşmiş olabilir? Kendi cümlelerinizle açıklayın.

Cevap:

Bu senaryoda ağacınız eğitim setini neredeyse mükemmel öğrendi ancak test setinde başarısı belirgin biçimde düştü. Bu, modelin veriyi ezberlediğini ve genellemediğini gösterir.

Soru: Eğitim veri setinde duyarlılık (sensitivity) değeri oldukça yüksek iken test veri setinde bu değerin belirgin biçimde düşmüştür. Bu durumu modelin performansı açısından yorumlayın.

Cevap:

Soru: Eğitim veri setinde yanlış sınıflandırma oranı (MCR) oldukça düşük iken test veri setinde bu oranın belirgin biçimde artmıştır. Bu durumu modelin performansı açısından yorumlayın.

Cevap:

Karar Ağacını Oluşturalım – Eğitim Veri Seti 2

Aşağıdaki adımları sırayla uygulayınız:

- CODAP’e **titanic_egitim_veri_seti2.csv** isimli veri setini yükleyiniz.
- **Hedef değişkeni** ağacın en üst kısmına sürükleyip bırakın.
- Veri tablosundaki **sex** değişkenini alıp ağacın üzerindeki **beyaz düğüme** sürükleyip bırakın.
- **Dişli çark** simgesine tıklayın. **Female** tarafını **pozitif** (*hayatta kaldı = 1*), **male** tarafını **negatif** (*hayatını kaybetti = 0*) olacak şekilde düzenleyin.
- Ağacın altındaki **gri dairelere (?)** tıklayarak **female** kutusunu **pozitif**, **male** kutusunu **negatif** olarak etiketleyin.

Karar ağacı tamamlandı. Bu aşamada herkesin **aynı karar ağacına** sahip olması beklenmektedir.

Karar Ağacını Okuyalım – Eğitim Veri Seti 2

Soru	Cevap
Kök düğüm kaç yolcu içeriyor? Kaçı hayatta?	
Female (kadın) kutusunda kaç kişi var? Kaçı hayatta?	
Male (erkek) kutusunda kaç kişi var? Kaçı hayatta?	
Hangi kutu ‘pozitif’ (hayatta) olarak etiketlendi?	

Değerleri Yazalım – Eğitim Veri Seti 2

Metrik	Formül	Hesaplama (Adım Adım)
Doğruluk (Accuracy)	$(TP + TN) / N$	
Duyarlılık (Sensitivity)	$TP / (TP + FN)$	
Özgüllük (Specificity)	$TN / (TN + FP)$	
Kesinlik (Precision)	$TP / (TP + FP)$	
Yanlış Sınıflandırma Oranı (MCR)	$(FP + FN) / N$	

Karar Ağacını Oluşturalım – Test Veri Seti 2

Şimdi aynı karar ağacını **farklı bir veri setine (test seti)** uygulayacaksınız. Bu veri seti de Titanic yolcularına ait ancak ağacın **daha önce hiç görmediği kayıtları** içermektedir.

Aşağıdaki adımları sırayla uygulayınız:

- CODAP'e **titanic_test_veri_seti2.csv** isimli veri setini yükleyiniz.
- **Hedef değişkeni** ağacın en üst kısmına sürükleyip bırakın.
- Veri tablosundaki **sex** değişkenini alıp ağacın üzerindeki **beyaz düğüm**e sürükleyip bırakın.
- **Dişli çark** simgesine tıklayın. **Female** tarafını **pozitif** (*hayatta kaldı = 1*), **male** tarafını **negatif** (*hayatını kaybetti = 0*) olacak şekilde düzenleyin.
- Ağacın altındaki **gri dairelere (?)** tıklayarak **female** kutusunu **pozitif**, **male** kutusunu **negatif** olarak etiketleyin.

Karar ağacı tamamlandı. Bu aşamada herkesin **aynı karar ağacına** sahip olması beklenmektedir.

Karar Ağacını Okuyalım – Test Veri Seti 2

Soru	Cevap
Kök düğüm kaç yolcu içeriyor? Kaçı hayatta?	
Female (kadın) kutusunda kaç kişi var? Kaçı hayatta?	
Male (erkek) kutusunda kaç kişi var? Kaçı hayatta?	
Hangi kutu 'pozitif' (hayatta) olarak etiketlendi?	

Değerleri Yazalım – Test Veri Seti 2

Metrik	Formül	Hesaplama (Adım Adım)
Doğruluk (Accuracy)	$(TP + TN) / N$	
Duyarlılık (Sensitivity)	$TP / (TP + FN)$	
Özgüllük (Specificity)	$TN / (TN + FP)$	
Kesinlik (Precision)	$TP / (TP + FP)$	
Yanlış Sınıflandırma Oranı (MCR)	$(FP + FN) / N$	

Soru: Eğitim ve test seti metrikleri arasında büyük bir fark var mı? Varsa bu fark neden olabilir?

Cevap:

Düşünelim: Bir model hem eğitim hem de test verisinde kötü performans sergiliyorsa ne düşünürsünüz? Bu model yeterince güçlü bir kural öğrenebilmiş midir?

Soru: Yetersiz uyum (underfitting) nedir? Bu senaryoda neden yetersiz uyum gerçekleşmiş olabilir? Kendi cümlelerinizle açıklayın.

Cevap:

Bu senaryoda ağacınız eğitim setini yeterince öğrenemedi ve hem eğitim hem de test setinde başarısı düşük kaldı. Bu, modelin verilerdeki temel ilişkiyi kavrayamadığını, yani eksik öğrendiğini gösterir.

Soru: Eğitim veri setinde duyarlılık (sensitivity) değeri oldukça yüksek iken test veri setinde bu değerin belirgin biçimde düşmüştür. Bu durumu modelin performansı açısından yorumlayın.


Cevap:

Soru: Eğitim veri setinde yanlış sınıflandırma oranı (MCR) oldukça düşük iken test veri setinde bu oranin belirgin biçimde artmıştır. Bu durumu modelin performansı açısından yorumlayın.


Cevap:

Aşırı Öğrenme (Overfitting): Modelin eğitim verisindeki detayları ezberlemesi sonucu bu veride çok başarılı olup, daha önce görmediği test verilerinde başarısız olması durumudur.


Eksik Öğrenme (Underfitting): Modelin verideki temel ilişkiyi kavrayamayacak kadar basit kalması nedeniyle eğitim ve test verilerinde yüksek hata oranı sergilemesi durumudur.



Aşırı Öğrenme



Eksik Öğrenme



Dengeli

Soru: “İyi” bir model nasıl olmalıdır? Hem eğitim hem test setinde hangi metriklerin nasıl olmasını beklersin?

Cevap:

Soru: Bu iki senaryo size bir modeli değerlendirirken sadece eğitim seti metriklerine bakmanın neden yeterli olmadığını nasıl gösterdi?

Cevap:

Soru: Bir modelin performansını yalnızca tek bir metriğe (örneğin doğruluk) bakarak değerlendirmek uygun mudur? Nedenini yazın.


Cevap:

Veri Setini Rastgele Bölme

Aşağıdaki adımları sırayla uygulayın:

- CODAP'e **titanic_veri_seti.csv** isimli veri setini yükleyin.
- Üst menüden **Plugins (Eklentiler)** sekmesine tıklayın.
- Açılan listeden sırasıyla **Data Moves** ardından **Choosy** seçeneklerini seçin.

Bu işlem, veri üzerinde seçim ve bölme yapmanızı sağlayan aracı açacaktır.



- Açılan Choosy panelinde **“Dataset”** sekmesine gidin.
- Çalışacağınız veri setini (titanic veri seti) seçin.



- Panelde **“Tag cases”** sekmesine tıklayın. Bu bölüm verileri gruplara ayırmak için kullanılır.
- Varsayılan olarak gelen **“Binary”** seçeneğini değiştirin. Bunun yerine **“Random” (rastgele)** seçeneğini seçin. Bu, verilerin rastgele dağıtılmasını sağlar.
- **“Proportion in group A”** alanına bir değer girin. Örneğin **20%** yazarsanız verilerin %20'si bu gruba atanır.
- Bu grubun neyi temsil edeceğini belirleyin:
 - **Call group A:** Test
 - **Call group B:** Eğitim

The screenshot shows the 'tag cases' tab in the Choosy panel. It contains the following fields and controls:

- 'proportion in group A:' with a text input field containing '20%' and a note '(Enter a fraction, decimal, or percentage)'.
- 'Call group A:' with a text input field containing 'Test'.
- 'Call group B:' with a text input field containing 'Eğitim'.
- A green plus icon followed by the text 'apply tags'.
- Below the main panel, 'Name for tag attribute:' with a text input field containing 'Tag'.

- Ayarları tamamladıktan sonra **“apply tags”** simgesine tıklayarak işlemi onaylayın.

- Veri tablonuza yeni bir değişken (**Name for tag attribute: Tag**) eklendiğini göreceksiniz.

The screenshot shows the 'titanic_veri_seti' dataset in the Data Studio interface. A new column named 'Tag' has been added to the dataset, highlighted by a red box. To the right, a confirmation dialog box with a green checkmark and the text 'Yay! The new "Tag" attribute is in collection "cases"!'. The dialog has an 'OK' button.

- Oluşan yeni değişkeni (**Tag**) sol tarafta bulunan “drop attribute to create new collection” alanına sürükleyip bırakın.

Bu işlem sonucunda veri setiniz iki ayrı gruba ayrılmış şekilde görselleştirilecektir.

The screenshot shows the 'titanic_veri_seti' dataset in the Data Studio interface. The 'Tag' attribute has been moved to the left sidebar, under the 'drop attribute to create new collection' section. A red arrow points from the 'Tag' attribute in the dataset table to the sidebar.

Artık veri setinizin:

- yaklaşık %80’inin eğitim (training)
- yaklaşık %20’sinin test (test)

olacak şekilde **rastgele bölündüğünü** gözlemleyebilirsiniz.

The screenshot shows the 'titanic_veri_seti' dataset in the Data Studio interface. The dataset is now split into two collections: 'Test' and 'Eğitim'. The 'Tag' attribute has been moved to the left sidebar, under the 'drop attribute to create new collection' section. A red arrow points from the 'Tag' attribute in the dataset table to the sidebar.